Trend Pulse

실시간 화제 키워드 — 프로토타입 v0.2 (리뷰 반영)

빅데이터개론 그룹 프로젝트 · Team **cloudnine**
노상현 · 김현서 · 김태형 · 이현호
2026-11 · 1차 스프린트

문제 정의

"요즘 사람들이 많이 이야기하는 건 뭘까?"

처음 기획안

- 미리 정한 키워드 목록
- DGIM 중심: 최근 N개 글 중 몇 개에 등장?
- 한계: **목록에 없는 새 화제는 못 잡음**

→

팀 논의 후 (현재)

- **키워드 목록 없이** 제목의 모든 단어 추적
- **감쇠 윈도우 중심** + 낮은 점수 제거
- DGIM은 보조: 선택한 키워드의 최근 N건 등장 수

> 키워드 목록 없이 화제를 발견하고, **저장 키워드 수를 줄였을 때 어떤 순위 오류가 생기는지** 측정했습니다.

두 질문을 따로 답합니다 — ① 근사가 정확 계산의 순위를 잘 재현하는가 ② 실제 사건을 화제로 발견하는가

데이터 & 구조

HuffPost 뉴스 20만 건을 날짜순으로 재생

스트림 재생
News Category Dataset
2012-01 ~ 2022-09
빈 제목 6·중복 링크 41 제거
209,480건

→

토큰화
제목 → 단어 집합(기사당 1회)
불용어·상투어 제거
약어 유지: AI, UK, EU, U.S.

→

감쇠 윈도우 + 제거
화제 순위 · Top K 진입 (주 기능)

정확 기준 방식
모든 키워드 유지 (비교용)

DGIM ↔ 정확 구간 집계
추적 키워드의 최근 N건 등장 수

→

웹 대시보드
화제 요약 → 근거 기사 → 비교·상세

Solar 에이전트
도구로 기사 조회, 인용 id를 앱이 검증

날짜만 있고 시각이 없음 → **과거 데이터 재생** (실시간 수집 아님)

2018년 이후 하루 약 5건 → 같은 1,000건이 **몇 달**

집계 메모리와 **관련 기사 인덱스·원문**은 따로 보고

알고리즘 (4주차)

감쇠 윈도우로 순위, DGIM으로 보조 집계

감쇠 윈도우 + 제거 주 기능

$$score(w) \leftarrow score(w) \cdot (1-c) + 1[w \in \text{새 기사}]$$

- c = 0.001: 영향이 **693건마다 절반**(반감기). 경계 있는 창이 아니며 최근 1,000건이 가중치의 63%
- 점수 < θ(0.5) 키워드는 **삭제**, 잃는 점수 < **θ/(1−θ)**
- 전체 감쇠는 전역 계수 하나로 O(1). 기사당 비용은 토큰 수만큼의 갱신 + 힙 관리

DGIM 보조 기능

$$\text{최근 } N\text{개 기사 중 키워드 등장 기사 수} \approx ?$$

- 크기 2^k 버킷, 크기별 최대 r개, 상대오차 ≤ **1/(2(r−1))**
- Top K 진입 시 자동 추적, **추적 시작 이후만** 계수 → 화면에 "관측 n/N건"
- 용량 300개: 현재 Top K·사용자 고정은 유지, 오래 비활성인 자동 추적부터 교체

> 단위 테스트 33개: 단순 구현과의 일치, 오차 상한, 추적 용량 정책, 잘못된 설정 거부, Solar 근거 검증(mock)

데모 · 2016-02-16 (스캘리아 대법관 사망 3일 뒤)

신규 진입 → 순위 역전 → 기사 근거

① Top K 진입 기록 — 키워드 목록 없이 포착

Top K 진입 기록

25

첫 진입 = 이번 재생(2016-01-01~)에서 처음 Top 20에 들어옴 · 재진입 = 2,000건 이상 밖에 있다가 복귀

2016-02-15	scalia	첫 진입	17위 · 19.71
2016-02-15	supreme	첫 진입	16위 · 19.52
2016-02-14	court	첫 진입	16위 · 19.48
2016-02-13	love	첫 진입	16위 · 18.28
2016-02-08	hampshire	첫 진입	19위 · 15.18
2016-02-08	marco	첫 진입	18위 · 16.05
2016-02-07	white	재진입	19위 · 14.56
2016-02-04	presidential	첫 진입	19위 · 13.97
2016-02-04	rubio	첫 진입	17위 · 14.76

② 메모리를 아낀 대가 — 정확 기준(빨강)과 scalia·rubio 순서가 바뀜, DGIM은 "관측 50"

순위	변동	키워드	점수	추이	기준	DGIM ≈ / 정확
14	▼1	gop	22.6		14	**23.5** / 25
15	▼3	rubio	20.8		16	**26.5** / 26
16	진입	scalia	20.7		15	**2** / 2 관측 50
17	▼2	iowa	19.7		17	**4.5** / 5

③ 근거 — 화제 요약과 대표 기사 (에이전트 인용 id는 조회 결과와 대조해 검증)

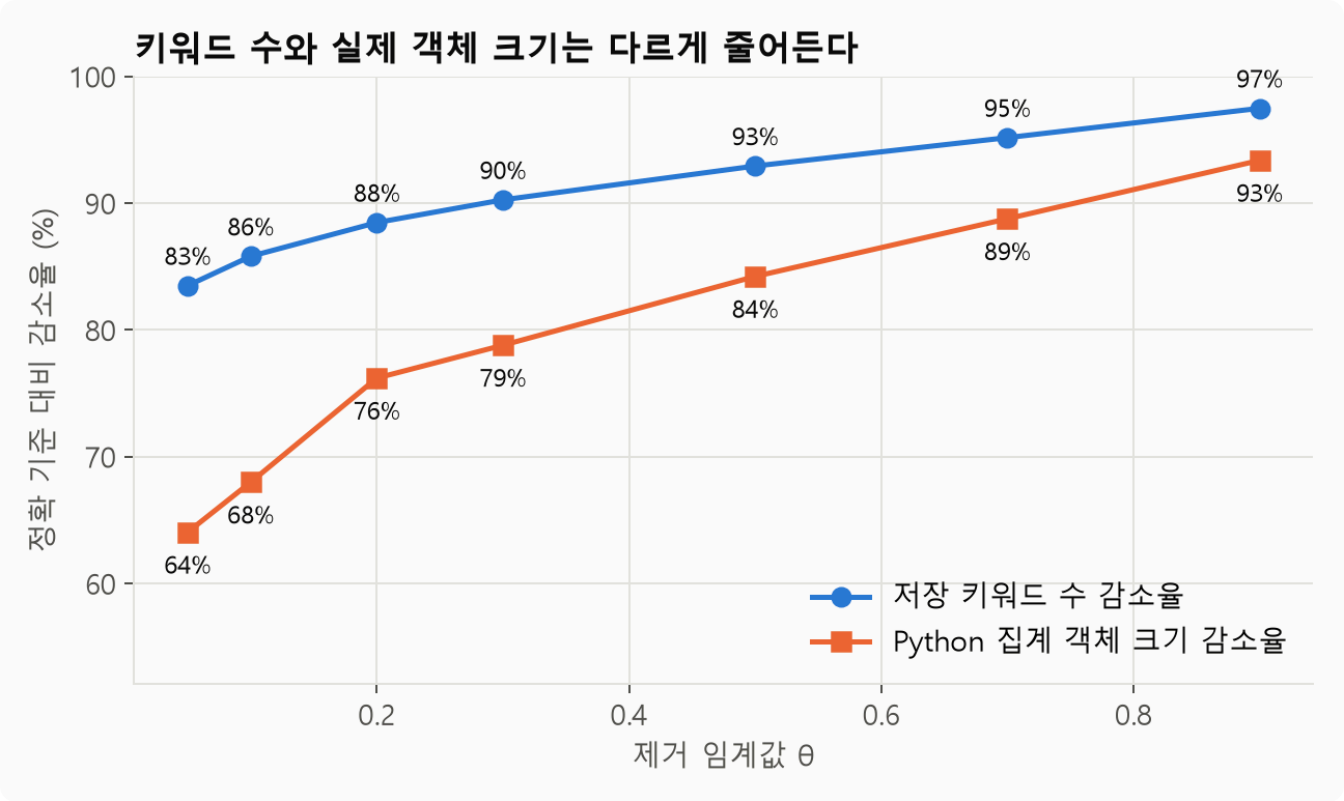
scalia · 16위 · 첫 진입 2016-02-15 (17위)

최근 1,000건 중 **24**건 · 그 이전 1,000건 중 1건 · 함께 등장: justice, antonin, court, supreme, death

1. **Supreme Court Honors Justice Scalia With Long-Standing Tradition** #134330 · 2016-02-16 · POLITICS
2. **Here's Why Stephen Colbert Will Miss Antonin Scalia** #134329 · 2016-02-16 · POLITICS
3. **Scalia's Thoughts On Jeb Bush May Surprise You** #134300 · 2016-02-15 · POLITICS

실험 1 · 메모리 (θ = 0.5, 전체 209,480건)

저장 키워드 수 92.9% 감소, 실제 객체 크기는 84.2% 감소



저장 키워드 수 (논리 지표)

2,854 / 40,265개

평가 구간 평균. 정확 기준은 본 단어를 모두 유지해 끝에는 54,995개

Python 집계 객체 크기 (실측)

0.68 / 4.31 MB

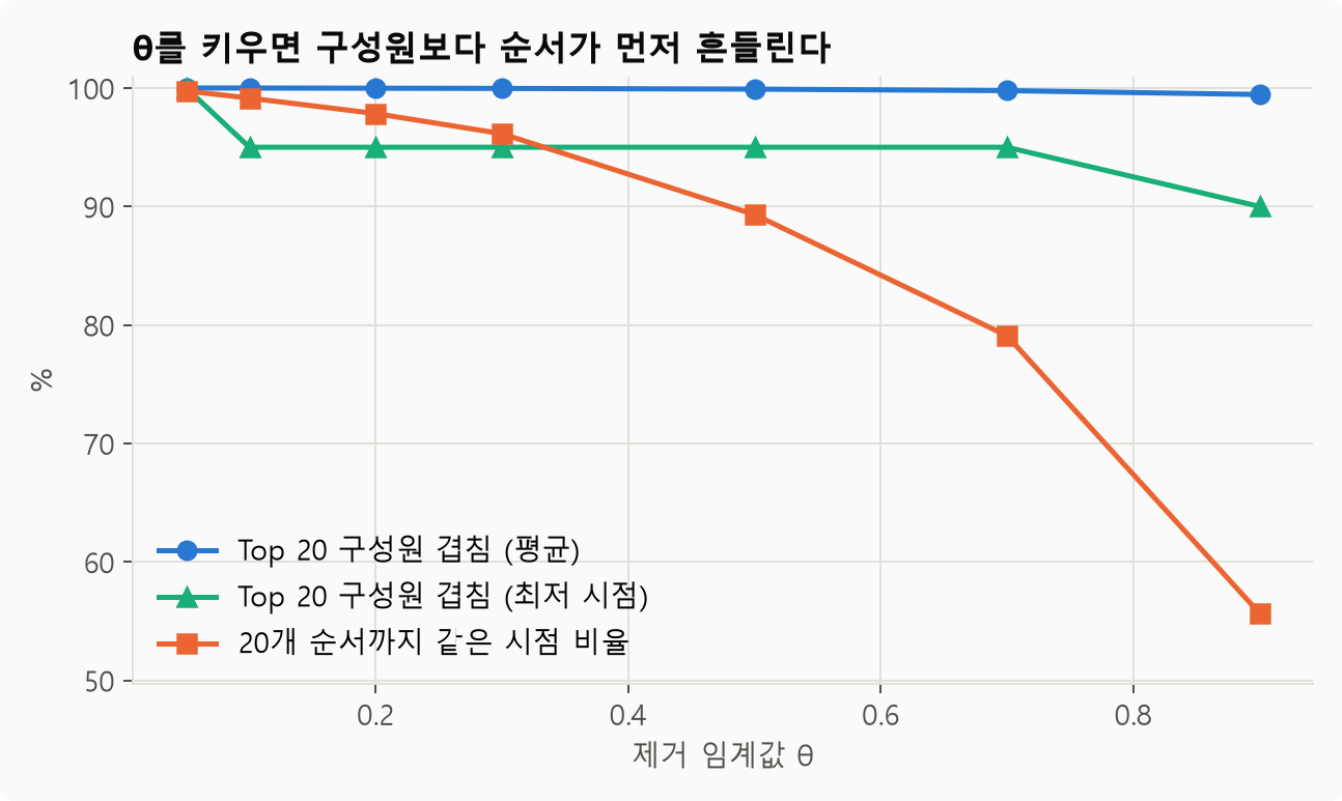
딕셔너리·키 문자열·float·**힙**을 재귀 측정. 기사 원문·인덱스·프로세스 전체 제외

리뷰에서 발견: 제거용 힙의 오래된 항목 때문에 v0.1(정리 기준 4배)에서는 θ=0.05일 때 객체가 정확 기준보다 컸다 → 1.2배로 바꿔 메모리·속도 모두 개선

c = 0.001 · 100건마다 순위, 20,000건마다 객체 크기 측정 · 처음 10,000건 제외

실험 2 · 순위 재현 (정확 기준과 비교)

구성원은 거의 같고, 순서가 먼저 흔들린다



θ = 0.5	값
Top 20 구성원 겹침 (평균)	**99.90%**
Top 20 구성원 겹침 (최저 시점)	95%
20개 순서까지 같은 시점	**89.3%**
Top 20 진입 이벤트 재현율 / 정밀도	99.8% / 99.9%
진입 시점이 늦은 이벤트	0.8% (최대 700건)
최대 점수 오차 / 이론 상한	0.39 / 1.0

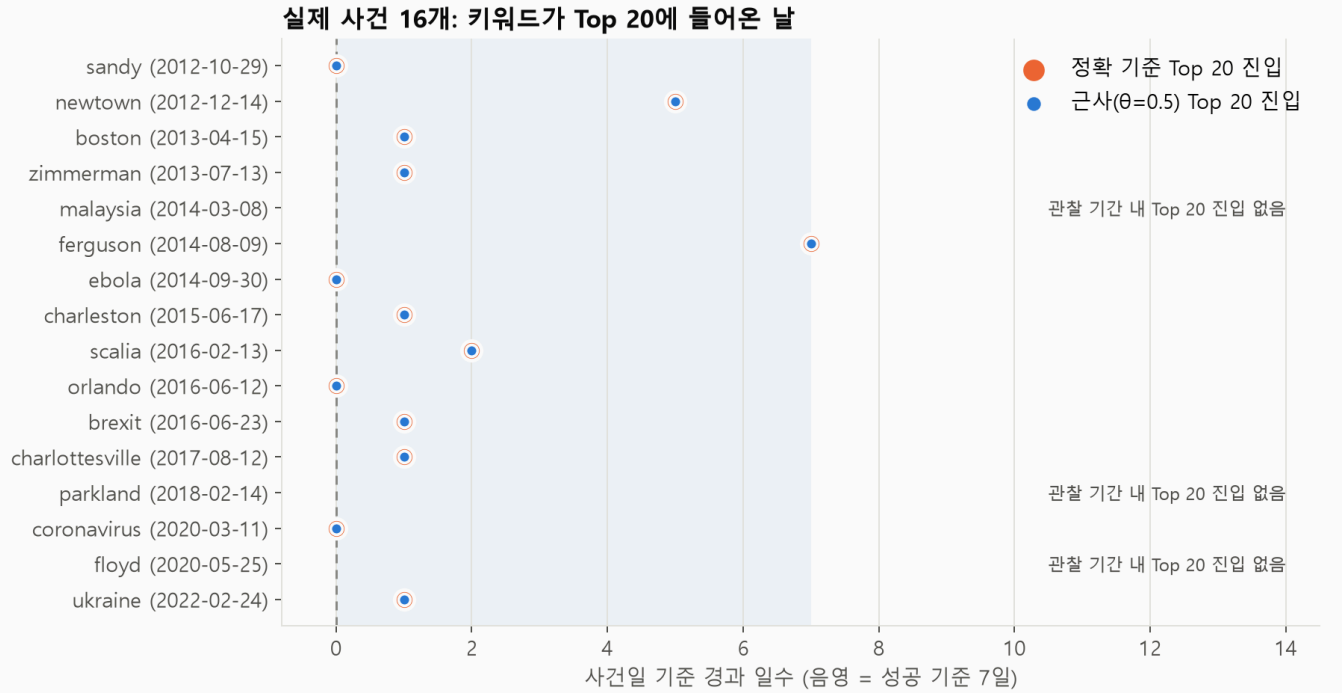
구성원 겹침 = 같은 시점 두 방식의 Top 20 집합이 겹치는 비율(순서 무관). 사람이 판단한 화제를 맞힌 비율이 아님 → 실험 3

> **실패 사례** θ=0.9: 정확 memorial 24.16 > wedding 24.08, 근사 23.36 < 24.08 → 점수 차이가 작으면 역전

이벤트 대응 허용 ±1,000건, 시점은 100건 스냅샷 단위 · 연도별 결과는 experiments/results/summary.md

실험 3 · 화제 발견의 유용성

실제 사건 16개 중 13개를 7일 안에 Top 20으로 발견



사건·키워드·성공 기준(사건일~7일 안 Top 20 진입)을 **결과를 보기 전에** 정함. 진입 시점은 **기사 한 건 단위**로 비교: 13건 중 12건은 근사와 정확이 같은 기사에서 진입(우크라이나만 2건 늦음)

실패 3건의 원인

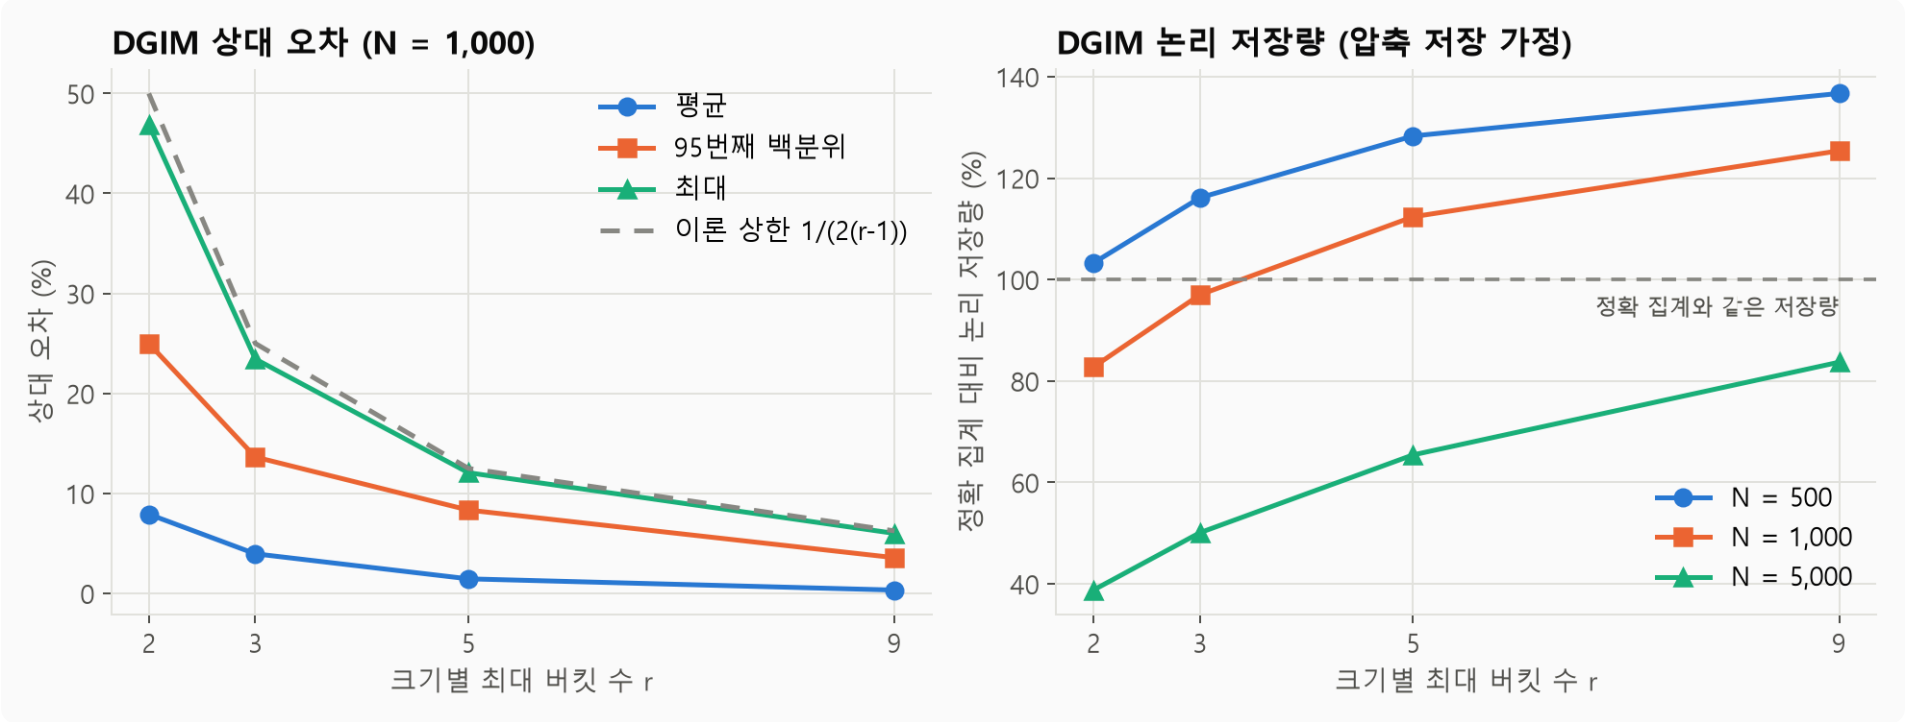
- **malaysia**: 데이터에 MH370 보도가 거의 없음(2주간 1건)
- **parkland**: 기사가 "florida·shooting"으로 부름 → 두 단어는 다음 날 진입 (표현 문제)
- **floyd**: 2020년 하루 6건 → 1,000건이 약 6개월 (기사 수 기준 감쇠의 한계)

표현·근거 적절성은 팀원이 casestudies.md 양식에 직접 평가할 예정

c = 0.001, θ = 0.5, K = 20 · 관찰 기간 사건일 −7일 ~ +14일

실험 4 · DGIM (보조 기능)

DGIM의 이득은 "무엇으로 재느냐"에 따라 달라진다



논리 저장량(압축 가정)으로는 N=500에서 DGIM이 103%로 손해, N=5,000에서 39%로 이득. **Python 실측**으로는 모든 구성에서 DGIM이 더 작음(34~85%) — 정확 쪽 deque의 고정 비용 때문. 두 수치를 섞지 않는다

오차는 모두 이론 상한 안. 중앙값 추정의 평균 오차 7.9% vs 교과서식 26.7%는 **등장 1~4회**에서 생긴 차이(6.4% vs 32.2%). 10회 이상은 11.0% vs 11.1%, Top 10 겹침도 같음

처리 성능 · 민감도

근사는 입력이 느리고 조회가 빠르다

같은 작업 범위, 5회 중앙값	정확 기준	근사 θ=0.5
입력 갱신만	561k 건/s	**143k 건/s**
Top 20 조회 1회	9.07 ms	**0.38 ms**
조회 대상 키워드	54,995개	3,511개

N = 1,000, r = 2	정확 구간	DGIM
입력 갱신만	882k 건/s	412k 건/s

엔진 전체 42k 건/s · API 응답 /api/state 6.4 ms. v0.1의 "속도 비교"는 작업 범위가 달라 철회하고 다시 쟀다

왜 입력이 느린가

근사는 갱신마다 제거용 힙에 넣고 빼는 작업이 추가된다. 대신 저장 키워드가 적어 순위 조회가 24배 빠르다

하루 안 기사 순서의 영향

같은 날짜 안 순서를 3번 섞어도 하루 끝 Top 20 겹침 99.3%, 첫 진입일 동일 약 91% (차이 p95 = 1일)

Python 3.14 · Windows 11 · 6코어 · 실행마다 ±10~30% 변동

정리

확인한 것, 한계, 다음 스프린트

확인한 것

- 키워드 목록 없이 사건 13/16 발견
- 키워드 수 −92.9%, 객체 크기 −84.2%
- Top 20 구성원 99.9% 일치, 대가는 **비슷한 점수끼리 순서 역전**
- DGIM 이득은 측정 기준·창 크기에 따라 다름

한계

- HuffPost 안의 화제일 뿐, 사회 전체 관심도가 아님
- 단어 단위 (parkland → florida·shooting)
- 희소 구간에서 기사 수 기준 감쇠가 느림
- Solar는 mock 검증만, 실제 키로 미확인

다음 스프린트

- Solar 실제 연동 + 답변 품질 평가
- 바이그램·개체명 묶기 (전후 비교)
- 날짜 기준 감쇠와 비교
- 급상승 탐지, 순위 불확실성 표시

> 코드·실험(summary.md, casestudies.md)·문서는 GitHub 저장소에 올릴 예정입니다. 피드백 부탁드립니다!