Trend Pulse

실시간 화제 키워드 — 프로토타입 v0.3

빅데이터개론 그룹 프로젝트 · Team **cloudnine**
노상현 · 김현서 · 김태형 · 이현호
2026-11 · 스프린트 3 (두 단어 묶기 · 날짜 감쇠 · 급상승 · 순위 불확실성)

문제 정의

"요즘 사람들이 많이 이야기하는 건 뭘까?"

처음 기획안

- 미리 정한 키워드 목록
- DGIM 중심: 최근 N개 글 중 몇 개에 등장?
- 한계: **목록에 없는 새 화제는 못 잡음**

→

팀 논의 후 (현재)

- **키워드 목록 없이** 제목의 단어·두 단어 구 추적
- **감쇠 윈도우 중심** + 낮은 점수 제거
- DGIM은 보조: 선택한 키워드의 최근 N건 등장 수

> 키워드 목록 없이 화제를 발견하고, **저장 키워드 수를 줄였을 때 어떤 순위 오류가 생기는지** 측정했습니다.

두 질문을 따로 답합니다 — ① 근사가 정확 계산의 순위를 잘 재현하는가 ② 실제 사건을 화제로 발견하는가

데이터 & 구조

HuffPost 뉴스 20만 건을 날짜순으로 재생



날짜만 있고 시각이 없음 → **과거 데이터 재생** (실시간 수집 아님)

2018년 이후 하루 약 5건 → 기사 수 기준 창은 **몇 달**에 해당

집계 메모리와 **관련 기사 인덱스·원문**은 따로 보고

알고리즘 (4주차)

감쇠 윈도우로 순위, DGIM으로 보조 집계

감쇠 윈도우 + 제거 주 기능

$$score(w) \leftarrow score(w) \cdot (1-c)^{\text{단계}} + 1[w \in \text{새 기사}]$$

- 단계 = 기사 1건 또는 **날짜 1일**(v0.3 기본, 반감기 7일)
- 점수 < θ(0.5) 키워드는 **삭제**, 잃는 점수 < **θ/(1−θ)**
- v0.3: 키워드가 다시 들어온 뒤 경과만큼 상한이 줄어드는 **키워드별 상한**

DGIM 보조 기능

최근 N개 기사 중 키워드 등장 기사 수 ≈ ?

- 크기 2^k 버킷, 크기별 최대 r개, 상대오차 ≤ **1/(2(r−1))**
- Top K 진입 시 자동 추적, **추적 시작 이후만** 계수 → "관측 n/N건"
- 용량 300개: 현재 Top K·고정 키워드는 유지, 오래 비활성인 자동 추적부터 교체

> 단위 테스트 50개: 단순 구현과의 일치, 오차 상한, **불확실성 표시 보장**, 추적 정책, 설정 검증, Solar 근거 검증(mock)

데모 · 2016-02-16 (스캘리아 대법관 사망 3일 뒤)

신규 진입 → 순위 불확실 → 기사 근거

① Top K 진입 기록 — 키워드 목록 없이 포착

Top K 진입 기록 25

첫 진입 = 이번 재생(2016-01-01~)에서 처음 Top 20에 들어옴 · 재진입 = 2,000건 이상 밖에 있다가 복귀

2016-02-16	grammys	첫 진입	17위 · 15.76
2016-02-15	justice	첫 진입	20위 · 13.11
2016-02-15	scalia	첫 진입	16위 · 15.06
2016-02-14	supreme court	첫 진입	14위 · 16.38
2016-02-12	love	재진입	19위 · 14.12
2016-02-12	democratic	첫 진입	18위 · 15.29
2016-02-11	primary	첫 진입	19위 · 13.25
2016-02-08	marco rubio	첫 진입	16위 · 14.23
2016-02-06	new hampshire	첫 진입	18위 · 13.42

② ≈ = 근사 때문에 순서가 바뀔 수 있음 — 실제로 정확 기준(빨강)에서 gop·scalia가 뒤바뀜

순위	변동	키워드	점수	추이	기준	DGIM ≈ / 정확
11 ≈	–	gop	20.2		12	23.5 / 25
12 ≈	▲4	scalia	20.2		11	5.5 / 7 관측 100
13	▼3	rubio	18.5		13	26.5 / 26

③ 근거 — 화제 요약과 대표 기사 (에이전트 인용 id는 조회 결과와 대조해 검증)

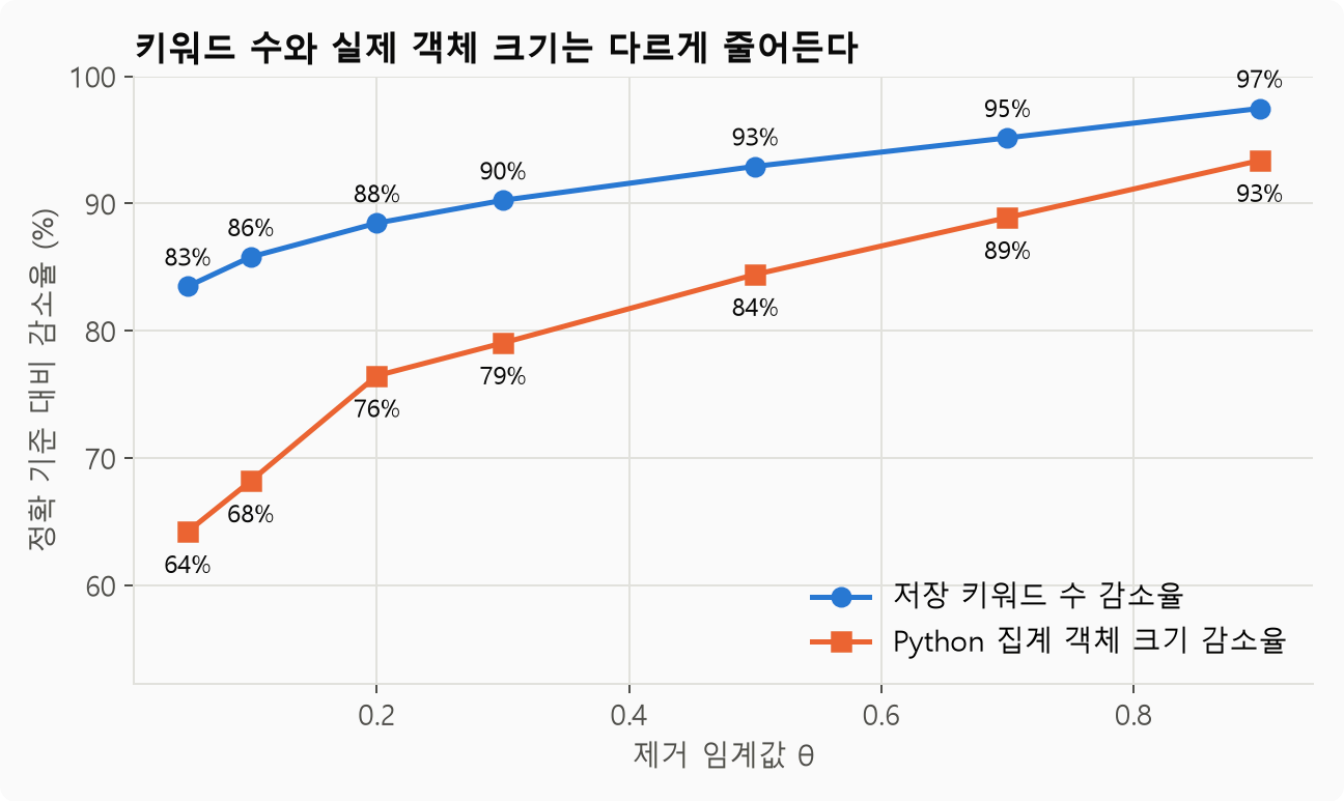
scalia · 12위 · 첫 진입 2016-02-15 (16위)

최근 11일 동안 **24**건 · 그 이전 11일 1건 · 함께 등장: justice, antonin, court, supreme, death

1. **Supreme Court Honors Justice Scalia With Long-Standing Tradition** `#134330 · 2016-02-16 · POLITICS`
2. **Here's Why Stephen Colbert Will Miss Antonin Scalia** `#134329 · 2016-02-16 · POLITICS`
3. **Scalia's Thoughts On Jeb Bush May Surprise You** `#134300 · 2016-02-15 · POLITICS`

실험 1 · 메모리 (단어, 기사 수 감쇠, θ = 0.5)

저장 키워드 수 92.9% 감소, 실제 객체 크기는 84.4% 감소



저장 키워드 수 (논리 지표)

2,854 / 40,265개

평가 구간 평균. 정확 기준은 본 단어를 모두 유지해 끝에는 54,995개

Python 집계 객체 크기 (실측)

0.66 / 4.24 MB

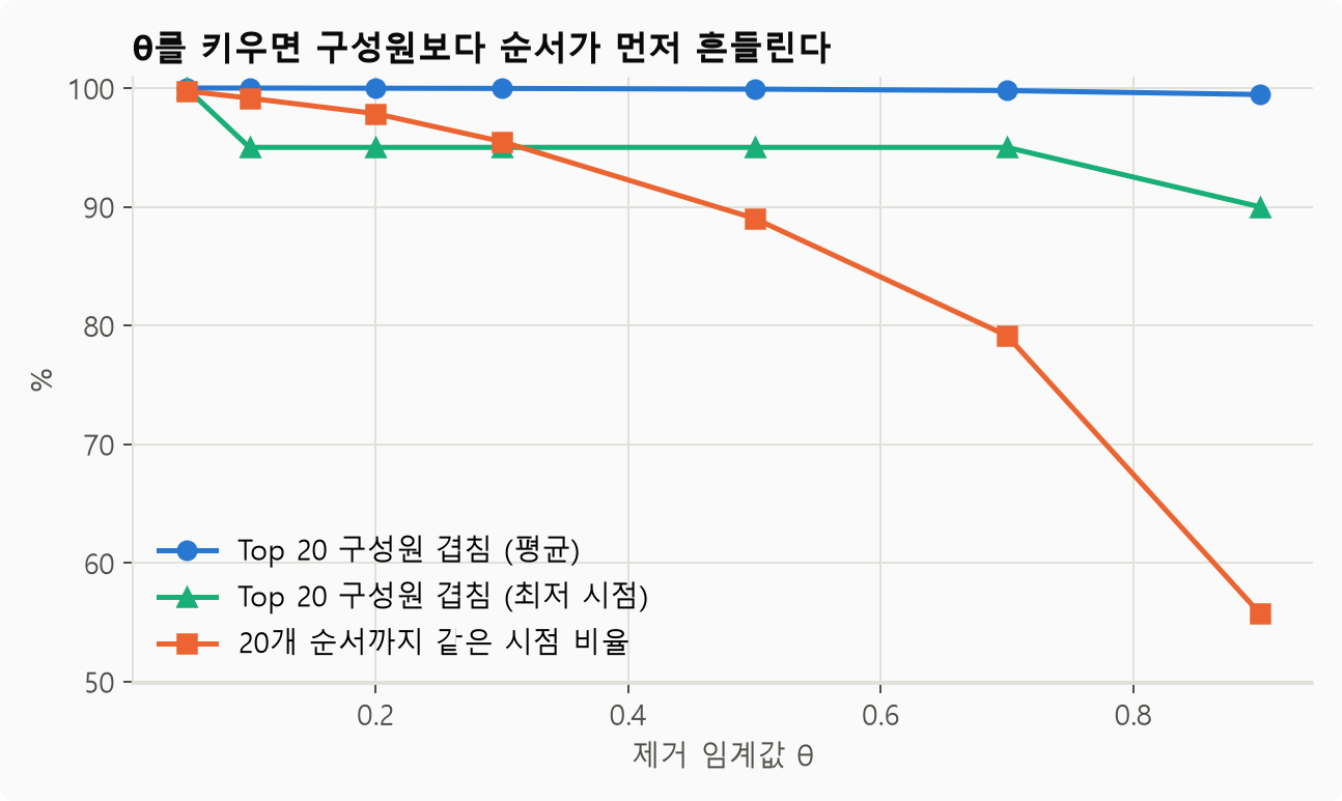
딕셔너리·키 문자열·float·**힙**을 재귀 측정. 기사 원문·인덱스·프로세스 전체 제외

v0.3: 두 단어 구를 넣으면 정확 기준이 19.5 MB로 커져 근사(1.03 MB)의 감소율이 **94.7%**가 된다. 근사 쪽도 1.56배로 커진다

c = 0.001 · 100건마다 순위, 20,000건마다 객체 크기 측정 · 처음 10,000건 제외 · v0.3 코드로 재실행한 값

실험 2 · 순위 재현 (정확 기준과 비교)

구성원은 거의 같고, 순서가 먼저 흔들린다



θ = 0.5	값
Top 20 구성원 겹침 (평균)	**99.91%**
Top 20 구성원 겹침 (최저 시점)	95%
20개 순서까지 같은 시점	**89.0%**
Top 20 진입 이벤트 재현율 / 정밀도	99.8% / 99.9%
진입 시점이 늦은 이벤트	0.7% (최대 700건)
최대 점수 오차 / 이론 상한	0.39 / 1.0

구성원 겹침 = 같은 시점 두 방식의 Top 20 집합이 겹치는 비율(순서 무관). 사람이 판단한 화제를 맞힌 비율이 아님 → 실험 3

> **실패 사례** θ=0.9: 정확 memorial 24.16 > wedding 24.08, 근사 23.36 < 24.08 → 점수 차이가 작으면 역전

이벤트 대응 허용 ±1,000건, 시점은 100건 스냅샷 단위 · 연도별 결과는 experiments/results/summary.md

실험 3 · 화제 발견의 유용성 v0.3 확장

날짜 기준 감쇠로 사건 26개 중 23개를 7일 안에 발견



사건일~7일 Top 20 진입	v0.2 사건 16	사전 등록 10
단어 · 기사 수 감쇠 (v0.2)	13	3
단어+구 · 기사 수 감쇠	13	3
단어+구 · 날짜 감쇠 7일	**14**	**9**

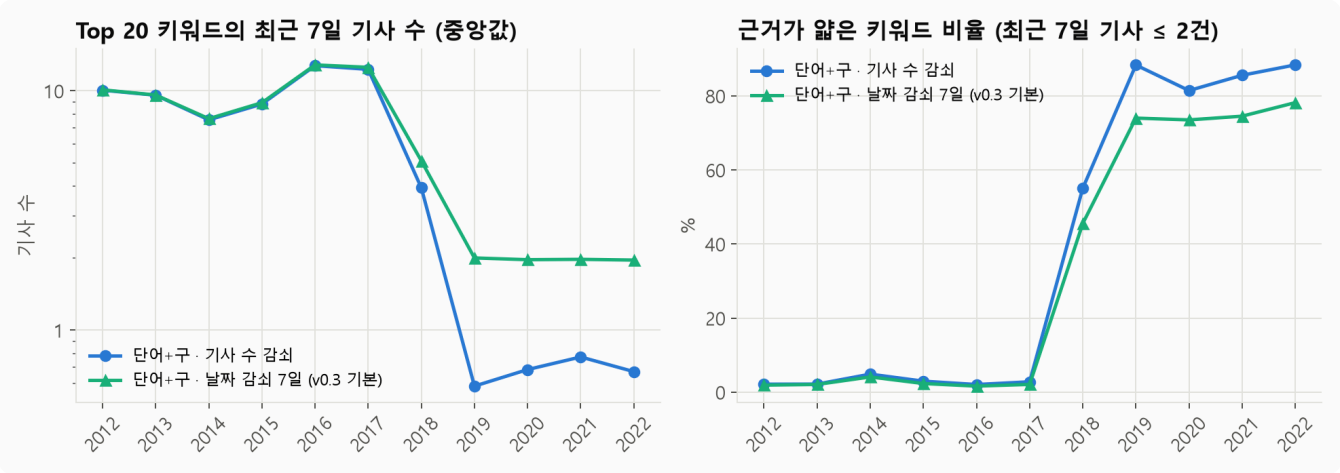
사전 등록 10개는 이번 실행 전에 사건·표현·기준을 정했다(공정한 비교). v0.2 사건에 붙인 추가 표현(parkland → school shooting 등)은 결과를 본 뒤라 사후 분석이다

2018년 이후 사건 6개(노트르담, 탄핵 조사, 코비, 의사당, 로 대 웨이드 등): 기사 수 감쇠는 하루 5건뿐이라 반응하지 못하고, 날짜 감쇠는 0~2일 안에 잡았다

θ = 0.5, K = 20 · 관찰 기간 사건일 −7일 ~ +14일 · 표현 목록 중 하나라도 진입하면 진입 · experiments/results/v03/summary.md

실험 3 · 날짜 감쇠의 대가 v0.3

희소 구간에서는 어느 쪽이든 근거가 얇다



기사 수 감쇠는 몇 달 전 기사가 순위를 지탱하고, 날짜 감쇠는 최근 기사를 반영하지만 하루 5건이라 1~2건짜리 키워드도 오른다. 2019년 이후 Top 20의 **73~78%**(기사 수 감쇠는 81~88%)가 최근 7일 기사 ≤ 2건

2019-04-16 노트르담 화재 다음 날 (날짜 감쇠)

순위	변동	키워드	점수	추이	기준	DGIM ≈ / 정확
1	▲1	notre dame	6.8		1	–
2	▲9	fire	4.9		2	–
3 ≈	▼2	trump	4.6		3	27.5 / 35 관측 259
4 ≈	▲10	cathedral	3.8		4	–
5	▼2	million	3.2		5	3.5 / 4 관측 59
6 ≈	▼2	shooting	2.4		6	5.5 / 7 관측 159
7 ≈	▼2	death	2.3		8	0 / 0 관측 9
8 ≈	▼2	dead	2.3		7	0 / 0 관측 9

notre dame·fire·cathedral이 1·2·4위(1~8위만 표시). 같은 화면의 19·20위에는 hole, hurt 같은 1~2건짜리 단어가 올라오고, 최근에 들어온 키워드가 많아 ≈도 많이 붙는다

하루 끝마다 Top 20 키워드 각각의 최근 7일 기사 수를 셈 · 단어+구

급상승은 더 빨리, ≈ 표시는 필요한 곳에만

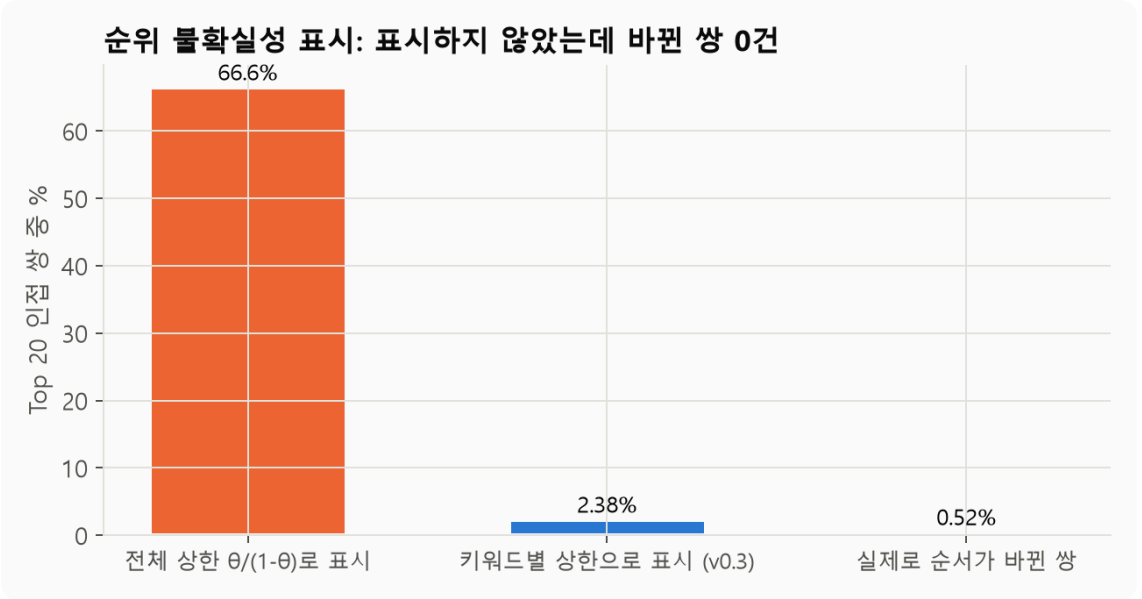
급상승 = 짧은 점수 – 긴 점수로 예상한 값



화면: 2019-04-16 노트르담 화재 다음 날의 급상승 패널

- 사건 26개 중 **24개**를 7일 안에 급상승 Top 10에 올림 (Top 20은 16개)
- **17개** 사건에서 Top 20보다 먼저, parkland는 급상승에서만 +1일
- 급상승 목록의 **48%**는 그 시점 Top 20에 없는 키워드

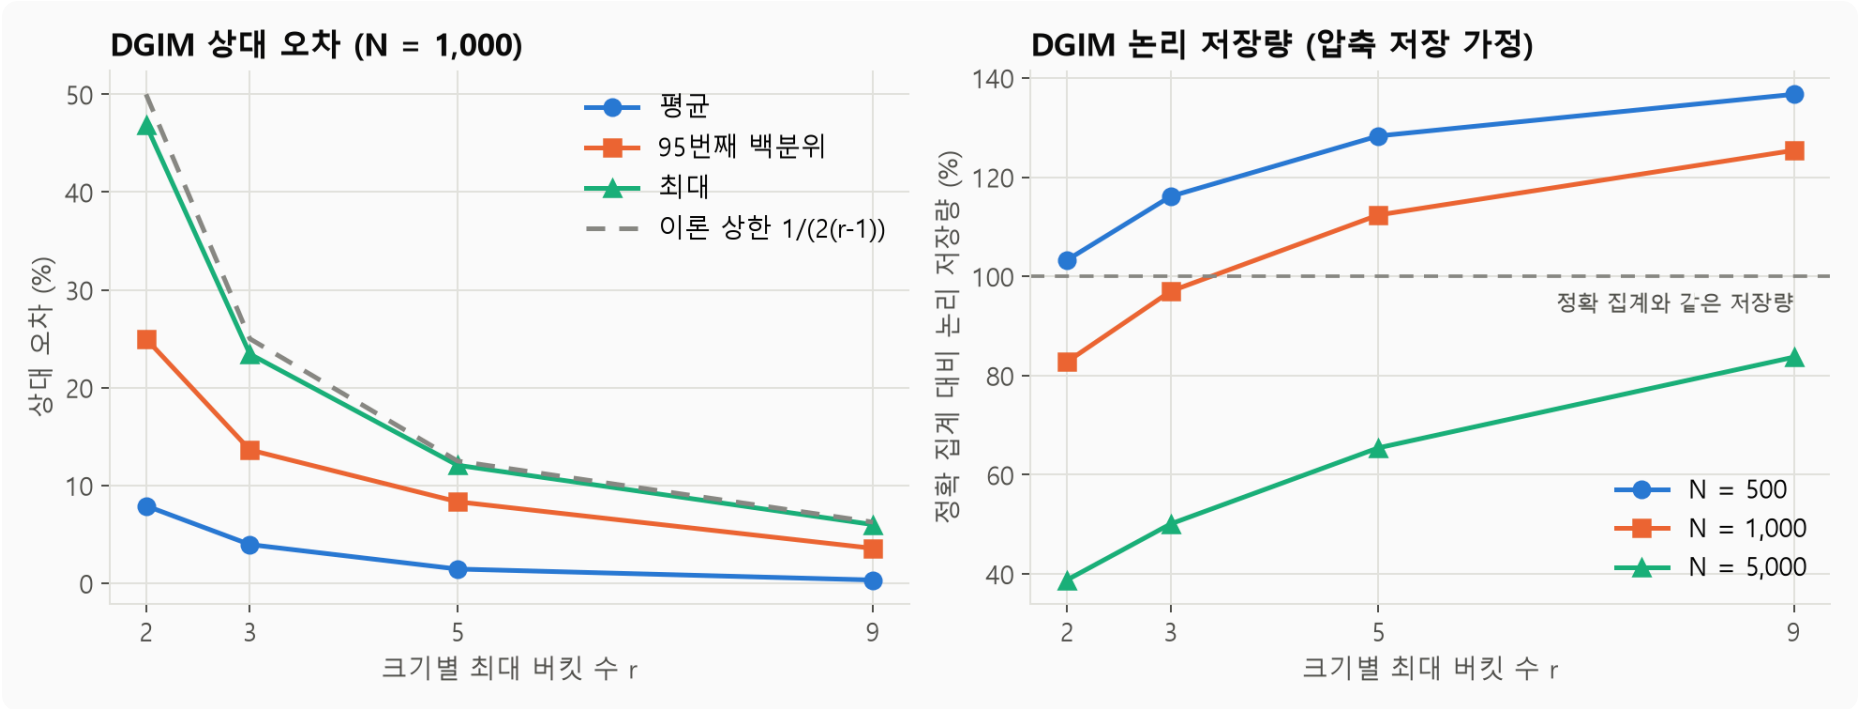
≈ 표시의 보장



- 정확 점수 ∈ [s, s + e): 아래 키워드가 $s_{i+1} + e_{i+1} > s_i$일 때만 ≈
- 인접 쌍 37,905개 중 **놓친 역전 0건**, 표시는 66.6% → 2.4%
- 대가: 키워드별 진입 시점 기억 → 객체 크기 +29.6%

실험 4 · DGIM (보조 기능)

DGIM의 이득은 "무엇으로 재느냐"에 따라 달라진다



논리 저장량(압축 가정)으로는 N=500에서 DGIM이 103%로 손해, N=5,000에서 39%로 이득. **Python 실측**으로는 모든 구성에서 DGIM이 더 작음(34~85%) — 정확 쪽 deque의 고정 비용 때문. 두 수치를 섞지 않는다

오차는 모두 이론 상한 안. 중앙값 추정의 평균 오차 7.9% vs 교과서식 26.7%는 **등장 1~4회**에서 생긴 차이(6.4% vs 32.2%). 10회 이상은 11.0% vs 11.1%, Top 10 겹침도 같음

처리 성능 · 에이전트

근사는 입력이 느리고 조회가 빠르다

같은 작업 범위, 5회 중앙값	정확 기준	근사 θ=0.5
입력 갱신만 (단어)	684k 건/s	**194k 건/s**
Top 20 조회 1회	11.35 ms	**0.51 ms**
조회 대상 키워드	54,995개	3,511개

엔진 전체 (모든 집계 + 스냅샷)	기사/s
단어만, 기사 수 감쇠 (v0.2 설정)	31k
v0.3 기본 (구·급상승 창·키워드별 상한)	20k

v0.3 기본은 약 35% 느리지만 대시보드 재생(틱당 최대 1,000건)에는 충분 · /api/state 18.5 ms

에이전트 평가 도구 (질문 33개)

오프라인 기준선: 근거 검증 33/33, 인용 89/89 유효. 사건 직후 아직 기사에 없는 구(`george floyd`)를 물으면 **어떤 단어로 답했는지 경고**하도록 고침

아직 못 한 것

Solar 실제 호출은 키가 없어 미실행. 키를 넣고 `eval_agent.py`를 돌리면 같은 표가 채워진다

Python 3.14 · Windows 11 · 6코어 · 실행마다 ±10~30% 변동

정리

확인한 것, 한계, 다음 스프린트

확인한 것

- 키워드 수 −92.9%, 객체 −84.4%, Top 20 구성원 99.9% 일치
- 대가는 **비슷한 점수끼리 순서 역전** → ≈로 표시(놓침 0)
- **날짜 감쇠**로 사전 등록 사건 9/10 (기사 수 감쇠 3/10)
- 급상승이 사건을 더 빨리 포착

한계

- HuffPost 안의 화제일 뿐, 사회 전체 관심도가 아님
- 2019년 이후 근거가 얇은 키워드가 많음
- 두 단어까지만 묶음
- Solar 실제 호출·팀원 채점 미완

다음 스프린트

- Solar 실제 평가 + 팀원 채점
- 근거 기사 수 표시·최소 근거 필터
- 날짜 모드 급상승 창 조정
- 세 단어 구, 무작위 날짜 표본 평가

코드·실험·문서: github.com/legendkimofficial/TrendPulse · 기본값을 날짜 감쇠로 바꾼 것에 대한 의견 부탁드립니다!